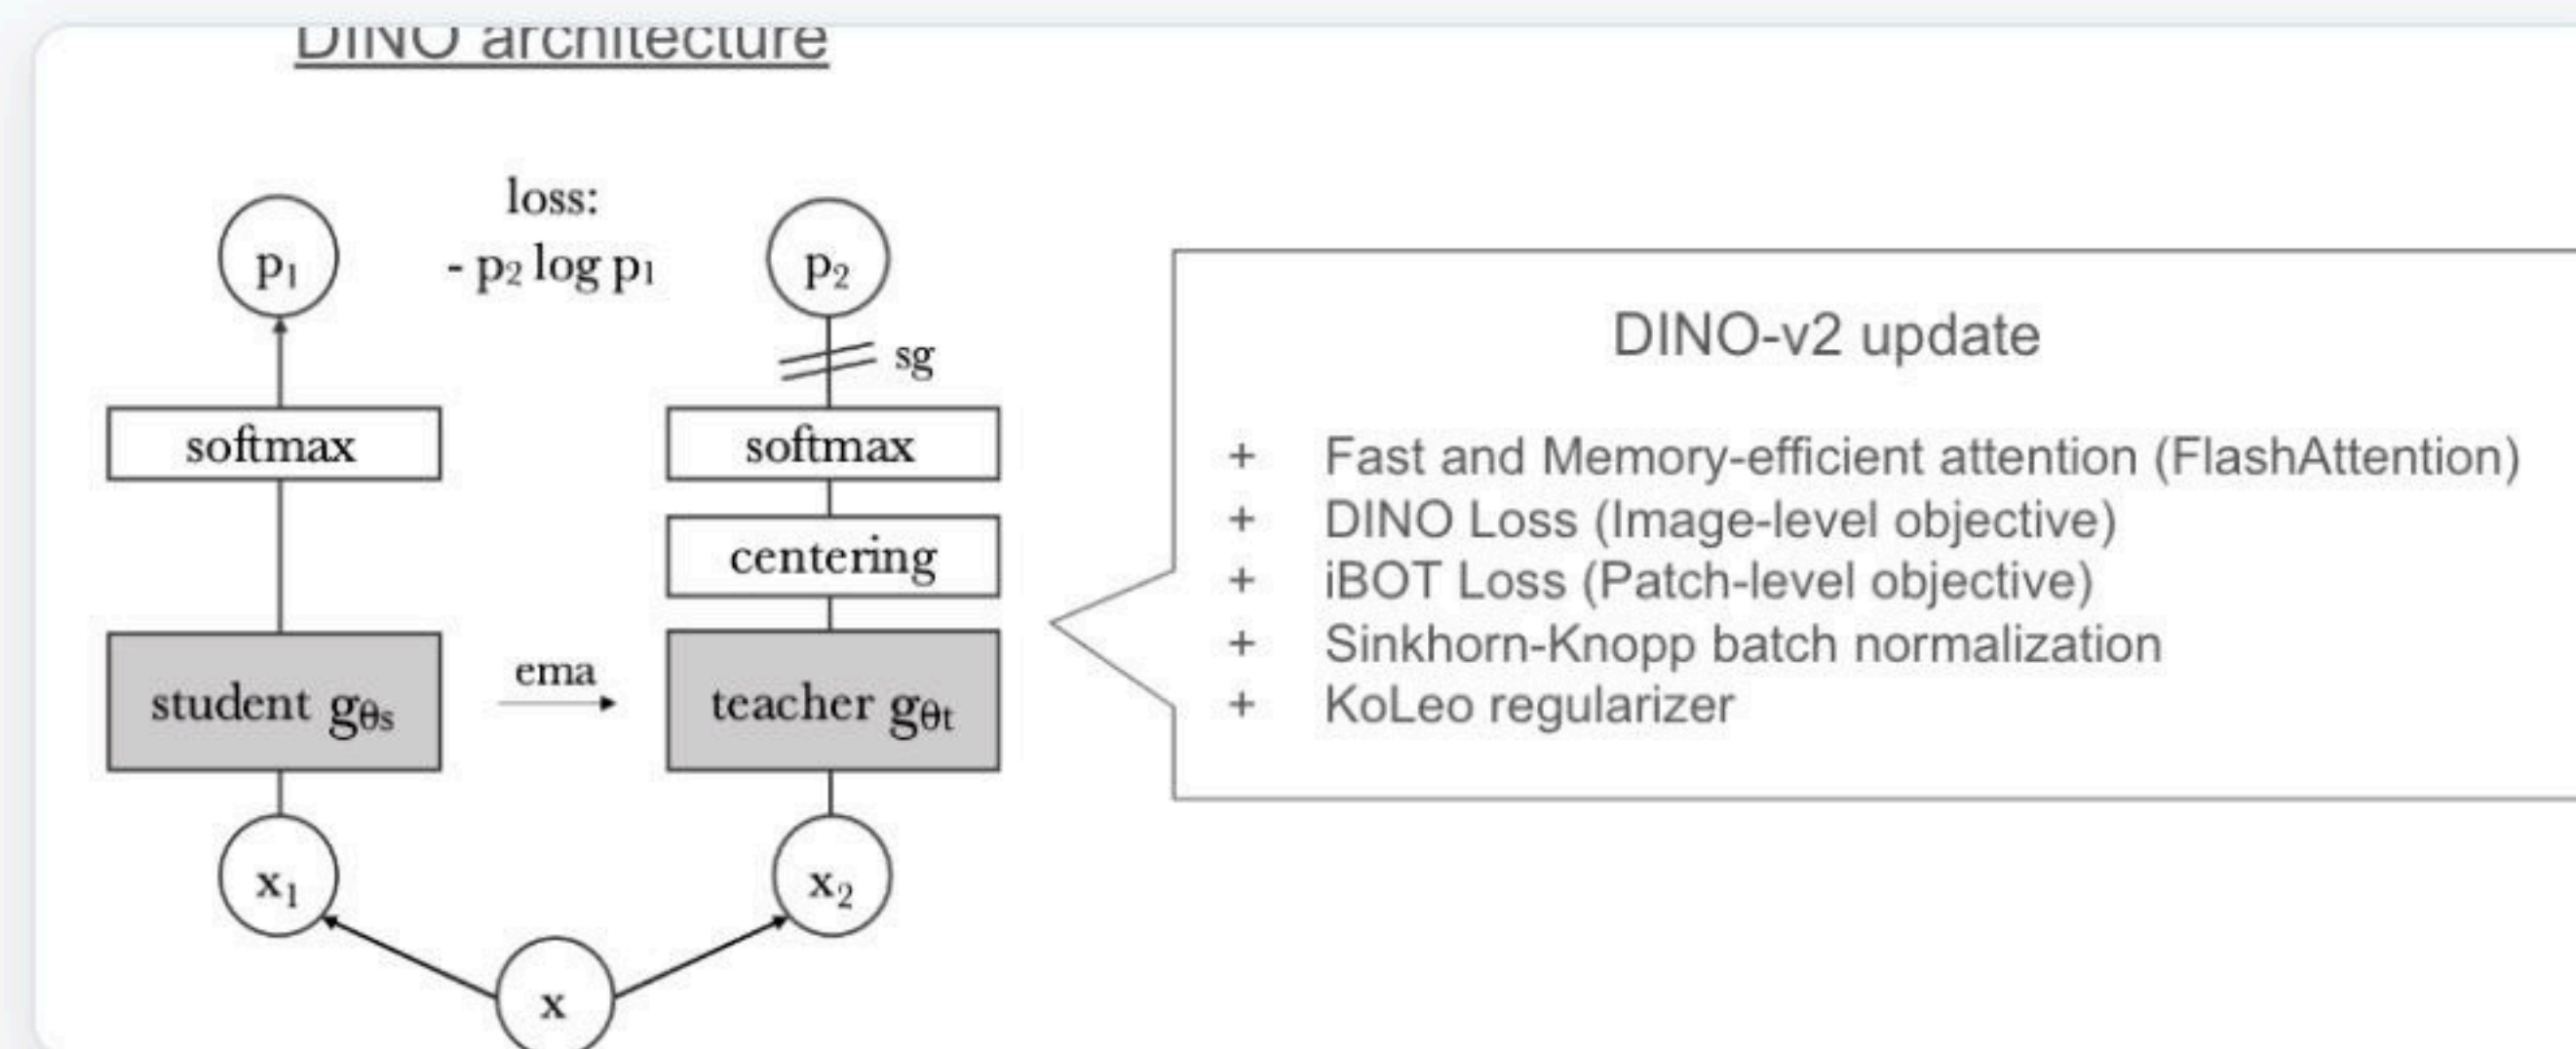


# שקף 1: סקירת הפרויקט (Project Review)

## Project Novelty

גישור על פער הנתונים (Catalog vs. Real World) באמצעות ייצור דאטה סינתטי מבוסס GenAI והעברת הידע לתמונות אמת מורכבות בעזרת Embeddings עוצמתיים.



## Motivation & Use Case

זיהוי אוטומטי של תקליטים המוחזקים בידי לקוחות בחנות לטובת ניתוח התנהגות צרכנים וייעול ניהול המלאי.

**Input/Output:** קלט - פריים RGB ממצלמת CCTV. פלט - מזהה אלבום (Class ID) וציון ביטחון.

## ?What Changed

מעבר מ-DINOv2 לגנרי לשימוש בגרסת ה-ViT-L/14 הגדולה, יחד עם לוגיקת **Smart Crop** (התמקדות ב-80% המרכזיים) לניקוי רעשי רקע.

# שקף 2: סקירת ספרות מדעית ועבודות קודמות

Slide 2: Previous Scientific Work (State-of-the-Art Review)


מאמר / שנה	משימה (Task)	שיטות עיקריות	קשר ישיר לפרויקט
DINOv2 (2023)	Visual Feature Extraction	Self-supervised ViT	הבסיס הטכנולוגי לחילוץ הוקטורים (Embeddings) המאפשרים זיהוי מדויק.
SDXL (2023)	Image Synthesis	Latent Diffusion	מודל הליבה (Generator) לייצור תמונות אימון סינתטיות באיכות גבוהה.
ControlNet (2023)	Spatial Control	Structural Conditioning	הכלי המרכזי לייצור וריאציות של אחיזה בזוויות שונות לפי מפות מבנה.
DIPSY (2024)	Domain Gap Strategy	IP-Adapter Guidance	אסטרטגיית הגישור לשמירה על זהות האלבוים (Identity) בתוך סביבות סינתטיות.

"השילוב בין מודלים יוצרים (SDXL/ControlNet) למודלים מבינים (DINOv2) הוא המפתח לפתרון בעיית המחסור בנתונים וגישור על פער המציאות"



# שקף 3: מאגר הנתונים וטכנולוגיית ייצור (Dataset & Generation)

התפלגות מחלקות אחידה (Class Distribution - Uniform)



*Perfect Balance (k=3 shot): מונע הטיות מודל (Bias) ומבטיח שהשוואת הביצועים בין האלגוריתמים תהיה אובייקטיבית לחלוטין.*

## תיאור מאגר הנתונים (Dataset Description)

- היקף המאגר: Baseline Support Set ייעודי לבדיקת עמידות להסתרות.
- כמות דגימות: 15 תמונות סינתטיות (חלוקה שווה ל-5 מחלקות).
- טכנולוגיית ייצור: שימוש במודלי SDXL ו-ControlNet יחד עם Nano Banana.
- סימולצית הסתרה: ייצור ידיים האוחזות בתקליט ומכסות 10-20% משטחו (פינות ושוליים).
- שיטת תיוג: Implicit Labeling - תיוג אוטומטי בזמן הייצור למניעת טעויות.

## ניתוח נתונים ראשוני (EDA)

מחלקה (Class Label)	דגימות	ייצוג	וריאציות
Ferdi Tayfur	3	20%	Poses 3
Marika Röck	3	20%	Poses 3
Michael Jackson	3	20%	Poses 3
Elvis Presley	3	20%	Poses 3
Billie Eilish	3	20%	Poses 3
סה"כ (Total)	15	100%	מאוזן (Balanced)

# שקף 4: פתרון בסיס ותוצאות (Baseline Solution & Results)

## מתודולוגיה (Methodology)

שימוש במודל **DINOv2 (ViT-L/14)** כ-Backbone קפוא. **חישוב רמת התאמה ויזואלית** מול בסיס הנתונים הסינתטי ובחירת התוצאה המקסימלית (Max Similarity Score).

## תוצאות הערכה (Evaluation)

מקרה בוחן	מחלקה שנחזתה	Confidence	סטטוס
Ferdi	Ferdi	0.76 (High)	Success ✓
Billie	Ferdi (Wrong)	0.49	Failure ✗
Marika	Marika	0.38 (Low)	Weak ⚠
Jackson	Marika (Wrong)	0.33	Failure ✗

## Error Analysis & Insights ⚠

**הצלחת Ferdi:** האובייקט ממורכז ודומיננטי בפריים. הציון הגבוה (0.76) מוכיח שהמרחב הוקטורי חסין להסתרות ידיים כשהאובייקט ממוקם נכון.

**כישלון Jackson/Billie:** במקרים אלו האלבומים היו מחוץ למרכז או קטנים יחסית לרקע.

**סיבת שורש:** הבייסליין משתמש ב-CenterCrop נאיבי. כשהאלבום בצד, המודל "מסתכל" על הרקע או על לבוש המשתמש, מה שמוביל לביטחון נמוך.

מסקנה: חילוץ המאפיינים עובד, אך המערכת זקוקה לרכיב של Object Detection (זיהוי אובייקטים) לפני שלב הסיווג.

# שקף 5: יעדים ותוכנית עבודה לסיום (Final Roadmap)

משימה (Task)	תוצר מצופה ויעדים (Expected Results & Goals)	סטטוס
 Synthetic Scaling	ייצור 1,000 תמונות High-fidelity לכל מחלקה (Ferd, Marika וכו') להרחבת האינדקס.	בביצוע
 Classifier Training	אימון "ראש" סיווג (Classifier Head) ייעודי על הנתונים הסינתטיים לשיפור ההפרדה.	בביצוע
 Robustness & Detection	הטמעת רכיב זיהוי אובייקטים (Object Detection) לפתרון בעיית המיקום בפריים.	בביצוע
 Accuracy Optimization	הגעה לדיוק (mAP) של מעל 90% על סט המבחן של עולם האמת (CCTV).	משימה קרובה
 GitHub & Summary	יעד סופי: העלאת מאגר קוד מסודר (Repo), תיעוד טכני מלא וסיכום ויזואלי של תוצאות הפרויקט.	משימה קרובה